

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное
учреждение высшего образования
«КАЗАНСКИЙ (ПРИВОЛЖСКИЙ) ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»

ИНСТИТУТ ФИЗИКИ

КАФЕДРА ФИЗИКИ МОЛЕКУЛЯРНЫХ СИСТЕМ

Направление подготовки: 12.03.04 Биотехнические системы и технологии

Профиль: Медицинское оборудование, физические принципы и
приборостроение

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
РАЗРАБОТКА АВТОМАТИЗИРОВАННОЙ СИСТЕМЫ ОБРАБОТКИ
ДАННЫХ ТОМОГРАФИЧЕСКИХ ИССЛЕДОВАНИЙ СЕРДЦА

Обучающийся 4 курса группы 06-161 _____ (Гареева Д.Р.)

Руководитель
д.ф.-м.н., профессор _____ (Ильясов К.А.)

Заведующий кафедрой физики молекулярных систем
д.ф.-м.н., профессор _____ (Скирда В.Д.)

Казань - 2025

ОГЛАВЛЕНИЕ

ОГЛАВЛЕНИЕ	2
СПИСОК СОКРАЩЕНИЙ.....	3
ВВЕДЕНИЕ.....	4
Глава 1. Теоретическая часть	6
1.1 МРТ – изображения	6
1.2 Dicom и NIfTI форматы	6
1.3 Сегментация изображений.....	8
1.4 Алгоритмы сегментации	12
1.5 Active Contour	13
1.6 Модель U-Net	15
Глава 2. Практическая часть	19
2.1 Реализация алгоритма Active Contour	19
2.2 Сбор и подготовка данных для обучения U-Net	22
2.3 Обучение U-Net.....	24
2.4 Сравнение классического метода и нейросетевого подхода	28
2.5 Расчет КДО и КСО	30
ОСНОВНЫЕ РЕЗУЛЬТАТЫ И ВЫВОДЫ	32
СПИСОК ЛИТЕРАТУРЫ.....	33

СПИСОК СОКРАЩЕНИЙ

КСО – Конечный систолический объем

КДО – Конечный диастолический объем

ИИ – Искусственный интеллект

МО – Машинное обучение

ПО – Программное обеспечение

СНН – сверточная нейронная сеть

ЛЖ – Левый желудочек

ВВЕДЕНИЕ

В российской системе здравоохранения, как и во всем мире, в настоящее время осваивают технологии искусственного интеллекта (ИИ), особенно это касается анализа медицинских снимков.

Чем же все-таки искусственный интеллект и машинное обучение (МО) помогают в медицинской визуализации? Ответ – эти методы повышают эффективность работы врачей благодаря автоматизации рутинных процессов, способствуют обеспечению более точной диагностики и повышают производительность работы специалистов. К примеру, модель ИИ может осуществить измерение патологии анатомических структур и сформировать предварительный протокол, за счет чего сокращается время, необходимое для анализа МРТ-снимков. Более конкретным примером может послужить метод повышения точности скрининга рака молочной железы на основе МО, разработанный учеными из Южной Кореи. Полученные результаты были опубликованы в The Lancet Digital Health [4].

МО также нашлось применение и в кардиологии. Так, например, в статье [2] на основе предсказаний нейронной сети было выявлено, что сферическая форма левого желудочка оказалась предвестником кардиомиопатии. Метод прикладного ИИ в данном разделе медицины постепенно становится общепринятым, обеспечивая повышение точности электро- и эхокардиографии, сонографии и лучевой диагностики сердечных заболеваний.

Цель данной работы: Разработать автоматизированную систему обработки данных томографических исследований сердца.

В соответствии с этой целью были поставлены следующие задачи:

1. Произвести сбор медицинских данных и осуществить их разметку.
2. Подобрать параметры алгоритма активных контуров для сегментации левого желудочка на МРТ-снимках и оценить его работу.
3. Обучить нейросетевую модель на собранных медицинских данных и проверить точность модели на тестовой выборке.

4. Сравнить алгоритмы и реализовать расчет конечных систолического и диастолического объемов на основе лучшего из них.

Глава 1. Теоретическая часть

1.1 МРТ – изображения

Магнитно-резонансная томография (МРТ) — это метод получения изображений поперечных срезов тела человека за счёт регистрации изменений в его магнитных свойствах. Для этого части тела помещаются в магнитное поле и подвергаются воздействию радиочастотных импульсов. Врач может использовать полученные изображения для оценки состояния и структуры внутренних органов.

Как и в случае с компьютерной томографией (КТ), данные, собранные сканером, обрабатываются компьютером для формирования изображения. Однако в отличие от КТ, МРТ не требует рентгеновского излучения. Вместо этого пациента помещают в мощный магнит, который выстраивает ядра водорода в тканях организма в определённом порядке.

После этого через тело пропускаются радиоволны, отклоняющие эти выровненные ядра. Когда они возвращаются в своё первоначальное положение, они испускают радиосигналы, которые улавливаются аппаратом. Разные типы тканей, включая опухоли, испускают сигналы различной интенсивности. Компьютер анализирует эти сигналы и формирует на их основе изображение. В некоторых случаях МРТ может создавать более детальные трёхмерные изображения, чем КТ. Изображения, полученные с томографов, чаще всего имеют формат dicom.

1.2 Dicom и NIfTI форматы

Что же такое dicom? *Dicom* (Digital Imaging and Communications in Medicine) — это международный стандарт, предназначенный для хранения, обработки и передачи медицинских изображений и сопутствующих данных между различными медицинскими устройствами и системами. Благодаря dicom можно работать с данными, полученными с томографов, рентгеновских аппаратов и других диагностических устройств, что позволяет применять их в диагностике, лечении и мониторинге состояния пациентов [18].

Файлы стандарта dicom имеют расширение «.dcm» и содержат в себе всю необходимую информацию о пациенте и о проведенном обследовании:

- ФИО пациента, его возраст, пол, вес и другие персональные данные.
- Сведения о медицинском учреждении, ФИО врача.
- Вид обследования, дата и время его проведения.
- Графическая информация (само изображение, например, рентгеновский снимок или результаты узи, МРТ и тд.).

Эти данные считываются специальными программами, например, Horos, dicom Viewer, Weasis, RadiAnt Dicom Viewer что позволяет точно диагностировать заболевание и определить оптимальную тактику лечения.

Файлы формата dicom [18] активно используются в машинном обучении. К примеру, после разметки МРТ-датасета (датасет – набор обучающих данных) брюшной полости с патологическими изменениями, такими как опухоли или метастазы, можно обучить модель для автоматизированной первичной диагностики онкологических заболеваний. Компьютерные алгоритмы [18] способны быстро анализировать большие объемы данных, исключая ошибки, связанные с человеческим фактором, например, усталостью или невнимательностью.

Формат *NIfTI* (Neuroimaging Informatics Technology Initiative) хранит медицинские изображения вместе с метаданными, необходимыми для их правильной интерпретации. Файл «.nii» содержит заголовок (header), в котором хранятся важные параметры:

- **dim** – размеры изображения (3D или 4D: ширина, высота, глубина, временные точки).
- **pixdim** – размер вокселя (разрешение в мм по осям X, Y, Z, T).
- **datatype** – тип данных (например, float32, int16).
- **bitpix** – количество бит на воксель.
- **qform_code** и **sform_code** – коды трансформации (связаны с ориентацией).

- **qoffset_x, qoffset_y, qoffset_z** – смещение изображения относительно начала координат.
- **srow_x, srow_y, srow_z** – матрицы аффинного преобразования (важны для совмещения с анатомическими данными).
- **toffset** – временной сдвиг первого снимка.
- **xyzt_units** – единицы измерения (например, миллиметры и секунды).
- **descrip** – описание данных (например, параметры сканирования).

Формат NIfTI также используется при создании масок для МРТ-снимков при формировании обучающего набора данных для нейросетевых алгоритмов. В МО, особенно для задач медицинской сегментации, маски используются для разметки интересующих областей на МРТ-снимках. Маска представляет собой бинарное или многоканальное изображение, где 0 обозначает фон, а 1, 2, 3 и так далее указывают на интересующие объекты. Файл маски обычно имеет формат «.nii» или «.nii.gz», который широко применяется в медицинской визуализации, так как позволяет хранить 3D и 4D изображения вместе с метаданными, описывающими их пространственное положение и параметры сканирования. Маска всегда совпадает по размерности с оригинальным снимком и может быть создана вручную с помощью программ, таких как MedSeg либо автоматически с помощью Python и библиотек, таких как nibabel и numpy.

1.3 Сегментация изображений

У понятия «сегментация изображения» существует множество определений, вот некоторые из них:

1. Сегментация изображения — это разбиение изображения на множество покрывающих его областей.
2. Сегментация изображения — задача поиска групп пикселей, каждая из которых характеризует один смысловой объект.

3. Сегментация изображений — это задача в области компьютерного зрения, заключающаяся в разделении изображения на несколько различных сегментов, каждый из которых соответствует определенному объекту [10].

Опираясь на эти определения, можно дать более общее: *сегментация изображения* (см. Рис. 1) — это фундаментальная задача компьютерного зрения, заключающаяся в структурированном разбиении изображения на совокупность непересекающихся и/или частично пересекающихся областей (сегментов), каждая из которых объединяет пиксели, обладающие схожими визуальными характеристиками и соответствующие отдельным семантическим объектам сцены.




Рисунок 1 - Пример сегментации нижнего отдела позвоночника на МРТ- снимке (слева – МРТ-снимок, справа – сегментированное изображение)

Существует несколько видов сегментации, каждая из которых предназначена для решения специфических задач и находит применение в различных сферах. Понимание их различий помогает подобрать наиболее подходящий метод обработки изображений.

Семантическая сегментация — это способ сегментации изображений, при котором каждый пиксель на изображении классифицируется как принадлежащий определенному классу. Основной особенностью семантической сегментации

является то, что она не различает отдельные экземпляры объектов одного класса [10]. Пример семантической сегментации (см. Рис. 2).




Рисунок 2 - Пример семантической сегментации нижнего отдела позвоночника на МРТ- снимке
(слева – МРТ-снимок, справа – сегментированное изображение)

Инстанс-сегментация (см. Рис. 3) — это более сложный вид сегментации по сравнению с семантической. Помимо классификации объектов, она также выделяет каждый из них как отдельный экземпляр. В результате, это позволяет точно отделить объекты, даже если они находятся близко или перекрывают друг друга.




Рисунок 3 - Пример инстанс-сегментации нижнего отдела позвоночника на МРТ- снимке (слева – МРТ-снимок, справа – сегментированное изображение)

Паноптическая сегментация (см. Рис 4) объединяет в себе оба вида сегментации – семантической и инстанс-сегментации. Ее задача — определить класс каждого пикселя на изображении, одновременно выделяя отдельные экземпляры объектов.




Рисунок 4 - Пример инстанс-сегментации нижнего отдела позвоночника на МРТ- снимке (слева – МРТ-снимок, справа – сегментированное изображение)

В медицинской визуализации сегментация помогает врачам выделять и анализировать органы, ткани и патологические образования на снимках КТ, МРТ или рентгеновских изображениях. Например, с ее помощью можно точно определить размеры опухоли, измерить объемы повреждений или классифицировать тип аномалий в клеточных структурах [10].

В данной работе требуется выделение левого желудочка как единого класса (см. Рис. 5) на изображении и не требуется различать левый желудочек между разными изображениями/экземплярами или отделять его от других структур. Это значит, что в данном случае поставлена задача семантической сегментации.




Рисунок 5 - Семантическая сегментация левого желудочка (LV) на МРТ- снимке (слева – МРТ- снимок, справа – сегментированное изображение)

1.4 Алгоритмы сегментации

На сегодняшний день существует множество алгоритмов, нацеленных на решение задачи всех видов сегментации. Следующие наиболее распространенные методы: пороговая сегментация (Global Thresholding, Adaptive Thresholding, Otsu's Thresholding.), методы на основе регионов (Region Growing, Split-and-Merge, Watershed), методы сегментации на основе границ (Оператор Собеля, Оператор Кэнни), методы на основе кластеризации (K-Means Clustering, Mean Shift,

DBSCAN), сегментация на основе активного контура [19] (Snakes, Active Contour Model (ACM), Gradient Vector Flow (GVF)).

В настоящее время активно применяются методы, основанные на технологиях глубокого обучения, в частности – сверточные нейронные сети, используемые для выполнения задачи сегментации изображений. Обучение таких моделей осуществляется на обширных наборах данных, содержащих размеченные [19] изображения. Среди наиболее популярных архитектур, применяемых для этих целей, можно выделить U-Net, Mask R-CNN и Panoptic FPN. Помимо этого, применяются и подходы, в которых изображение представляется в виде графа. В рамках таких методов сегментация осуществляется путем поиска минимального разреза графа, что позволяет разделить изображение на отдельные сегменты. Примерами подобных подходов являются Normalized Cut, Max-Flow/Min-Cut и Random Walks. Эти методы [19] часто объединяют под общим названием — графовые методы сегментации.

В данной работе для решения задачи сегментации левого желудочка сердца были выбраны два алгоритма: классический – Active Contour и современный подход – нейросетевой метод. Выбор подходящих алгоритмов осуществлялся по следующим критериям: тип изображения (градации серого или цветное, двумерное или трехмерное наличие шума или артефактов), скорость и точность работы алгоритма, количество входящих параметров, тип сегментируемых объектов, тип сегментации (семантический), форма анатомической структуры (левый желудочек имеет преимущественно округлые очертания), количество классов (два класса: фон - 0 и желудочек - 1).

1.5 Active Contour

Метод активных контуров, предложенный в 1987 году [3], используется для решения различных задач обработки изображений, включая обнаружение контуров, тонких структур, границ объектов, а также сегментацию и отслеживание движения. Этот подход основан на вариационной модели, в основе которой лежит

активный контур — кривая, изменяющая свою форму в процессе минимизации специально заданного энергетического функционала. Структура функционала выбрана так, чтобы при достижении локального минимума контур совпадал с нужной особенностью изображения, например, с границей объекта, подлежащего сегментации [3] (см. Рис. 6).




Рисунок 6 - Пример работы метода активных контуров для сегментации изображения. Красный контур – начальная инициализация контура, синий контур – финальный контур после 10, 20, 30, 40, 50, 60, 70, 100 итераций соответственно (слева-направо, сверху-вниз)

Активный контур представляет собой параметрическую кривую, которая в процессе изменения своей формы стремится к минимуму определённого энергетического функционала. Этот функционал включает два основных компонента: внутреннюю и внешнюю энергию. Внутренняя энергия отвечает за свойства самой кривой, такие как её гибкость и гладкость, то есть определяет её упругость и сопротивление деформации. Внешняя энергия, в свою очередь, формируется на основе характеристик изображения, в частности его

интенсивности, и её структура может варьироваться в зависимости от конкретной задачи обработки изображения.

Активный контур (также называемый деформируемым контуром или снейком) — это параметрическая кривая на изображении, заданная координатами x, y и описываемая следующим образом [3]:

$$C(s): [0, 1] \rightarrow R^2, s \rightarrow C(s) = (x(s), y(s))^T,$$

где s — параметр кривой, а x, y декартовы координаты на плоскости изображения.

Рассмотрим определение энергии активного контура. Она задаётся с помощью функционала, имеющего следующую форму:

$$E_{snake}(C) = \int_0^1 E_{int}(C(s)) + E_{ext}(C(s)) ds,$$

где $E_{int}(C(s))$ — внутренняя энергия контура, определенная как

$$E_{int}(C(s)) = \alpha(s)|C'(s)|^2 + \beta(s)|C''|^2,$$

где $\alpha(s)$ регулирует упругость контура и $\beta(s)$ регулирует жесткость контура. А $E_{ext}(C(s))$ — внешняя энергия, определенная как

$$E_{ext}(C(s)) = P(C(s)).$$

Функция P называется потенциалом и описывает внешнее влияние на активный контур, которое определяется характеристиками изображения. Конкретный вид потенциала подбирается в зависимости от поставленной задачи. Часто потенциал представляет собой комбинацию нескольких компонентов, каждый из которых выделяет определённые свойства изображения [3].

Реализация данного алгоритма на языке Python будет рассмотрена во 2 главе.

1.6 Модель U-Net

U-Net — это архитектура сверточной нейронной сети, разработанная для эффективной и точной сегментации изображений. Она была создана во Фрайбургском университете и представлена в 2015 году на International Symposium on Biomedical Imaging, где показала выдающиеся результаты, в том числе достигла

наилучшей точности в сегментации рентгеновских снимков. С тех пор U-Net широко применяется в задачах машинного обучения, особенно в медицинской визуализации.

На изображении (см. Рис. 7) представлена архитектура сверточной нейронной сети U-Net. Основная идея данной архитектуры заключается в симметричной структуре, состоящей из сжимающей (downsampling) и восстанавливающей (upsampling) части, соединенных между собой так называемыми skip-соединениями, которые обеспечивают передачу пространственно-значимой информации между соответствующими уровнями.




Рисунок 7 - Архитектура U-Net [4]

На вход подается одноканальное (может быть и 3 канала, в нашем случае МРТ – снимок черно-белый, поэтому канал 1) изображение размером 256×256 пикселей, далее оно проходит через серию сверточных блоков. Каждый из блоков, как показано на рисунке 7, содержит в себе 2 последовательных свёрточных слоя с ядрами 3×3, функцией активации ReLU и нормализацией по мини-батчу (Batch Normalization). Такие блоки на схеме обозначены красными стрелками (см. Рис 7). После каждого блока применяются операции субдискретизации посредством

MaxPooling с ядром 2×2 – они снижают пространственное разрешение, при этом увеличивая глубину карты признаков. Эти операции обозначены на рисунке 7 черными стрелками.

С увеличением глубины уровня, увеличивается и количество используемых каналов, что в свою очередь соответствует увеличению количества извлекаемых признаков. После четырех уровней сжатия данные достигают так называемого "бутылочного горлышка" — это центральная часть U-Net с минимальным пространственным разрешением (16×16), при этом с наибольшим количеством каналов (1024). На этом уровне также используется слой Dropout для регуляризации, предотвращающей переобучение. Данный слой обозначен на схеме фиолетовой стрелкой.

После центральной части начинается процесс восстановления пространственного разрешения. Реализация процесса проходит при помощи транспонированных свёрточных слоёв, которые выполняют операцию увеличения размерности (upsampling). Эти слои обозначены зелёными стрелками. Каждый из транспонированных слоев восстанавливает пространственное разрешение до предыдущего уровня и объединяется с соответствующим по разрешению выходом из сжимающей части с помощью операции конкатенации (skip connection). Такое объединение позволяет сохранить как локальные, так и глобальные признаки, что критически важно для точной сегментации.

В итоге из последовательных шагов восстановления формируется выходное изображение, которое в результате преобразуется в необходимое количество каналов (например, в зависимости от числа классов в задаче сегментации) посредством финального свёрточного слоя.

Рассматривая структуру модели количественно, получаем, что в архитектуре содержится 16 стандартных свёрточных слоёв с активацией ReLU и Batch Normalization, 4 операции субдискретизации через MaxPooling, 1 свёрточный блок с Dropout в центральной части, а также 4 транспонированных свёрточных слоя в декодере. Помимо этого, реализованы 4 skip-соединения между энкодером и

декодером, обеспечивающие передачу признаков между уровнями с одинаковым пространственным разрешением.

Глава 2. Практическая часть

2.1 Реализация алгоритма Active Contour

Инструменты разработки и анализа данных

Реализация алгоритма Active Contour осуществлялась на языке Python 3.9 в двух средах программирования - PyCharm и Jupyter Notebook. Также для работы с алгоритмом были установлены следующие пакеты: NumPy, OpenCV, Scikit-image, Matplotlib.

Python 3.9 отлично подходит для сегментации изображений благодаря богатой экосистеме библиотек (OpenCV, NumPy, PyTorch, TensorFlow) и простому синтаксису. В связке с PyCharm — мощной и удобной средой разработки — он позволяет быстро писать, отлаживать и визуализировать код, управлять зависимостями, использовать Jupyter Notebook и легко подключать библиотеки для машинного обучения, что делает его идеальным инструментом для задач компьютерного зрения.

1. NumPy: Библиотека для работы с многомерными массивами данных, позволяющая качественно и быстро выполнять манипуляции с данными и математические операции.
2. OpenCV (Open Source Computer Vision Library): Продвинутый инструмент для обработки изображений и видео. Предоставляет набор функций для чтения, обработки и анализа визуальных данных.
3. Scikit-image: Библиотека, специализирующаяся на обработке изображений. Содержит разнообразные методы для выполнения операций, таких как фильтрация, морфологические операции и сегментация.
4. Matplotlib: Библиотека для создания визуализаций и графиков. Используется для визуализации изображений и результатов сегментации [19].

Предобработка данных

Были использованы несколько этапов предобработки (см. Рис. 8) МРТ - снимков перед подачей в алгоритм активного контура. Сначала, МРТ-снимки были конвертированы из dicom/ima формата в png. Далее, была проведена нормализация

данных к диапазону от 0 до 255 и увеличено количество каналов изображения до 3. После этого была применена пороговая фильтрация (отбрасывание более темных пикселей) и морфологическая обработка – удаление шумов и мелких объектов. Также при предобработке использовалось выравнивание уровня интенсивности ярких областей между всеми снимками, чтобы выровнять яркость области ЛЖ. Затем последовало выделение контуров анатомических структур, которое было достигнуто с помощью усиления границ на снимке. И, в заключение, усиливается контраст изображения и возвращается одноканальный снимок.




Рисунок 8 - МРТ-снимок левого желудочка (а), МРТ-снимок после предобработки (б), МРТ-снимок после пороговой сегментации (без нормализации) (в)

Реализация алгоритма активных контуров с помощью пакета Skimage

Для сегментации левого желудочка были подобраны следующие параметры алгоритма активных контуров: $\alpha=0.00001$, $\beta=5$, $\gamma=0.01$, $w_edge=2$, $w_line=0.5$, $max_num_iter=1000$, $convergence=0.1$, $max_px_move=1$.

Альфа (α) - параметр формы длины контура, более высокие значения заставляют контур сокращаться быстрее. Бета (β) – параметр отвечающий за формы плавности контура, более высокие значения делают контур более плавным. Гамма (γ) – явный параметр шага по времени. Управление притяжением к краям регулируется параметром край (w_edge) - при использовании отрицательных значений контур отталкивается от краев. Контролирует притяжение к яркости параметр направления (w_line), при отрицательных значениях контур будет

притягиваться к темным областям. Максимальное количество итераций (max_num_iter) – максимальное количество итераций для оптимизации размера и формы контура. Критерий конвергенции (convergence) и максимальное расстояние перемещения пикселей за одну итерацию (max_px_move).

Результат работы алгоритма на серии из 12 снимков представлен ниже (см. Рис. 9).




Рисунок 9 – Результат работы алгоритма активных контуров на МРТ-снимках от диастолы до систолы (слева-направо, сверху-вниз)

Оценка точности производилась с помощью коэффициента Дайсона на 20 пациентах (по 25 снимков на каждого):

$$\text{Dice} = \frac{2 \cdot \sum(P \cdot G)}{\sum P + \sum G},$$

где $\sum(P \cdot G)$ - количество совпадающих пикселей, где и предсказание, и истина равны 1, $\sum P$ - количество пикселей, где предсказание = 1, $\sum G$ - количество пикселей, где истина = 1.

Коэффициент Дайсона составил $\text{Dice} = 0.72$. Алгоритм показал лучший результат на пациентах со стандартными размерами и формами ЛЖ, однако оказался чувствительным к пациентам, у которых КДО и КСО имеют большую разницу. Также для данного алгоритма необходима ручная инициализация начального контура, что является еще одним недостатком. Еще одним недостатком является сложность подбора размера начального контура.

2.2 Сбор и подготовка данных для обучения U-Net

Для обучения сверточной нейронной сети был собран датасет из 75 пациентов. Снимки имели формат dicom или ima, на каждого из пациентов приходилась серия из 25 МРТ-снимков, реже из 12 снимков. Для поиска нужного набора снимков использовалась программа Weasis (см. Рис. 10). В ней осуществлялся просмотр и извлечение интересующей серии. Сердце рассматривалось в сагиттальной плоскости, и для последующего анализа необходимо было провести прямую, ориентированную вдоль его центральной (анатомической) оси. На основании данной ориентации выбирался аксиальный срез, на котором идентифицировался левый желудочек. Далее желудочек условно разделялся поперечно по его средней линии, что служило основой для выбора серии изображений в косой плоскости – искомая серия снимков. Всего было отобрано 1875 снимков.




Рисунок 10 – Окно программы Weasis с МРТ – снимками сердца в разных плоскостях. Для сохранения конфиденциальности данные пациентов скрыты

Для обучения модели необходимо было осуществить разметку данных, а именно, выделить на МРТ - снимке левый желудочек. Разметка изображений осуществлялась в программе MedSeg (см. Рис. 11, 12).

MedSeg — это бесплатный онлайн-инструмент с возможностями ручной сегментации и сегментации на основе искусственного интеллекта. Инструмент полностью работает в браузере и не требует регистрации. Оптимизирован для КТ и МРТ изображений.

В данной работе использовался MedSeg для работы с dicom файлами и сохранением масок в формате nii. В процессе можно было просматривать информацию о текущем срезе на картинке и настраивать автоматическую предразметку. Из инструментов использовались кисть с масштабом, заполнение замкнутой области [20].




Рисунок 11 – Программа MedSeg с загруженным МРТ-снимком до и после выделения ЛЖ




Рисунок 12 – Программа MedSeg с полученной ппi маской

В итоге был получен набор данных для обучения модели, состоящий из 1875 МРТ-снимков и 1875 масок.

2.3 Обучение U-Net

Перед обучением модели, данные были нормализованы и приведены к единому размеру 256*256 (см. Рис. 13).




Рисунок 13 – Слева – МРТ-снимок, справа – маска

Архитектура U-Net не менялась и была стандартной. Подбирались параметры обучения модели, такие как размер батча и количество эпох. Также использовалась валидационная выборка и аугментация данных для качественного обучения и предотвращения переобучения.

Проверка работы алгоритма проходила на тестовой выборке из 15 пациентов (362 снимка). Метриками точности предсказаний нейронной сети были выбраны коэффициент Дайсона (Dice) и пересечение по объединению (IoU).

IoU оценивает степень пересечения между предсказанной и реальной областями сегментации и рассчитывается по формуле:

$$IoU = \frac{TP}{TP + FP + FN} = \frac{Dice}{2 - Dice},$$

где True Positive (TP) — истинноположительные пиксели, False Positive (FP) — ложноположительные пиксели, False Negative (FN) — ложноотрицательные пиксели.

Коэффициент Дайсона на тестовой выборке составил $Dice = 0.88$, а $IoU = 0.84$. Пример результата работы модели на одной из серии снимков из тестовой выборки (см. Рис. 14, 15).




Рисунок 14 – Результат работы U-Net на тестовых снимках (до дообучения)




Рисунок 15 - Результат работы U-Net на тестовых снимках (до дообучения)

На этих снимках (см. Рис. 15) видно, что модель работает неточно при сегментации желудочка нестандартной формы. Для лучшей работы на такого рода данных, модель пришлось дообучить.

После дообучения коэффициент Дайсона на тестовой выборке составил $\text{Dice} = 0.91$, а $\text{IoU} = 0.89$. Предсказания модели представлены на рисунке 16.




Рисунок 16 – Результат работы модели на снимках из тестовой выборки после дообучения

Модель показала эффективную работу на тестовой выборке, продемонстрировала устойчивость на нестандартных данных (шумы, разные фазы сердечного цикла и тд.), обобщающую способность и самое главное высокую точность сегментации.

2.4 Сравнение классического метода и нейросетевого подхода

В рамках данной работы для сегментации левого желудочка были реализованы два алгоритма: активный контур (классический метод) и сверточная нейронная сеть (нейросетевой метод). Ниже будут рассмотрены преимущества и недостатки каждого из них.

Преимущества классического метода заключаются в простоте реализации: по сравнению с нейронной сетью меньшее количество параметров и не требует предварительного обучения. Также для метода активных контуров нет необходимости создавать большие наборы данных, что является главным преимуществом перед нейросетевым подходом. Однако, *классический алгоритм имеет свои недостатки*. К ним относятся: зависимость от начального приближения контура, чувствительность к шуму и слабовыраженным границам, низкая устойчивость к вариативности форм и размеров ЛЖ, ограниченная точность при сложной морфологии сердца.

Нейросетевой метод. *Преимущества* - высокая точность и полнота сегментации (коэффициент Дайсона – 0.91), хорошая обобщающая способность, устойчивость к шуму и различным вариациям изображений. *Недостатком* является необходимость подготовки размеченного датасета, следовательно, есть зависимость от объема и качества обучающих данных.

Ниже приведена таблица со сравнением обоих алгоритмов (см. Табл. 1):

Критерий	Активные контуры	U-Net
Требования к размеченным данным	Нет	Да
Обобщающая способность	Низкая	Высокая
Требуется обучение	Нет	Да
Автоматизация процесса	Частичная	Полная
Коэффициент Дайсона	0.72	0.91
Устойчивость к шуму и слабовыраженным границам	Средняя	Высокая

Таблица 1 – Сравнение нейросетевого (U-Net) и классического (Активные контуры) метода

В итоге нейросетевой метод U-Net значительно превосходит классический подход активных контуров по точности, устойчивости к шуму и способности обрабатывать изображения с низким качеством границ. Несмотря на необходимость предварительного обучения и наличие размеченного набора данных, использование U-Net является более предпочтительным в практических задачах автоматизированной сегментации ЛЖ. То есть расчёт КДО и КСО будет осуществлен на основе работы нейросетевой модели.

2.5 Расчет КДО и КСО

Конечные диастолический и систолический объёмы рассчитываются на основе сегментированных ЛЖ. Стоит отметить каждый пиксель в `dicom` соответствует реальному физическому размеру и хранится в теге `PixelSpacing`. В итоге формула площади выделенной области имеет следующий вид:

$$A = N \cdot S_r \cdot S_c ,$$

где, A — площадь выделенной области (в мм^2), N — количество пикселей в сегментированной области (значения маски равны 1), S_r — размер пикселя по вертикали (мм), S_c — размер пикселя по горизонтали (мм).

На рисунке 17 представлен пример рассчитанных конечных систолического и диастолического объёмов.




Рисунок 17 - Демонстрация рассчитанных конечных диастолического(слева) и систолического объемов(справа). Total segmented voxels - Общее количество сегментированных вокселей, Total segmented volume - Общий объем сегментированной области в мл

Автоматизированный расчёт конечных диастолического и систолического объёмов позволяют дать количественную оценку функциональному состоянию ЛЖ сердца на основе медицинских изображений формата dicom. Использование информации о физическом размере пикселей (тег PixelSpacing) обеспечивает точность в определении площади и объёма сегментированных областей, что может быть полезно в клинической практике для диагностики и мониторинга сердечно-сосудистых заболеваний.

ОСНОВНЫЕ РЕЗУЛЬТАТЫ И ВЫВОДЫ

1. В рамках работы была обучена и протестирована нейросетевая модель архитектуры U-Net, которая продемонстрировала высокую точность сегментации — 91%, что подтверждает её эффективность при анализе томографических изображений сердца.
2. Для обучения модели был сформирован набор данных, включающий около 1875 пар изображений, что обеспечило достаточное разнообразие данных и повысило обобщающую способность модели.
3. Также реализован алгоритм сегментации на основе метода активных контуров, показавший точность 72% на тестовой выборке. Этот результат подтвердил преимущество сверточных нейронных сетей над классическими методами при решении задачи сегментации.
4. На основе результатов лучшей модели разработан модуль автоматизированного расчета конечных систолического и диастолического объемов, что позволяет количественно оценивать функциональные характеристики сердца.

Таким образом, в ходе исследования была разработана и реализована автоматизированная система обработки томографических данных сердца, основанная на сверточной нейронной сети. Система позволяет существенно сократить время анализа МРТ-изображений и повысить точность диагностических заключений, что делает её перспективным инструментом для применения в клинической практике.

СПИСОК ЛИТЕРАТУРЫ

1. Kass, M., Witkin, A., & Terzopoulos, D. Snakes: Active contour models // International Journal of Computer Vision. – 1988. – Vol. 1, No. 4. – P. 321–331.
2. Vukadinovic, M., Kwan, A. C., Yuan, V., Salerno, M., Lee, D. C., Albert, C. M., Cheng, S., Li, D., Ouyang, D., Clarke, S. L. Deep learning-enabled analysis of medical images identifies cardiac sphericity as an early marker of cardiomyopathy and related outcomes // The Lancet Digital Health [Электронный ресурс]. – 2025. – DOI: 10.1016/S2589-7500(25)00098-2 (дата обращения: 03.02.2025).
3. Вариационные методы в анализе изображений [Электронный ресурс] // Курс лекций по вариационным методам. – МГУ, 2022. – Режим доступа: <https://imaging.cs.msu.ru/files/courses/varmethods2022/varmethods2022-book-2.pdf> (дата обращения: 08.02.2025).
4. The Lancet Digital Health [Электронный ресурс]. – Режим доступа: <https://www.thelancet.com/journals/landig/home> (дата обращения: 12.06.2025).
5. Ильясов, К. А. Принципы получения изображений в МРТ [Электронный ресурс] / К. А. Ильясов. – Казанский федеральный университет, 2010. – 94 с. – Режим доступа: https://kpfu.ru/portal/docs/F_1277485057/Principy.polucheniya.izobrazhenij.v.MRT.Ilyasov.pdf (дата обращения: 02.02.2025).
6. Современные методы визуализации в диагностике заболеваний: метод. рекомендации [Электронный ресурс]. – Режим доступа: <https://omnidocor.ru/upload/iblock/686/686baa3df8c5badac73f4dfb9a21afb7.pdf> (дата обращения: 12.06.2025).
7. МРТ: T1 и T2-последовательности [Электронный ресурс] // 24Radiology. – Режим доступа: <https://24radiology.ru/fizika/mrt-t1-i-t2-posledovatelnost/> (дата обращения: 12.06.2025).
8. DICOM – Википедия [Электронный ресурс]. – Режим доступа: <https://ru.wikipedia.org/wiki/DICOM> (дата обращения: 11.03.2025).

9. Что такое DICOM и зачем он нужен? [Электронный ресурс] // TrainingData. – Режим доступа: <https://trainingdata.ru/markup-dark-side-ml/tpost/2c5j5toet1-chto-takoe-dicom> (дата обращения: 15.03.2025).
10. ООО «Data Light». Сегментация изображений в Computer Vision [Электронный ресурс] // Блог компании Data Light. – URL: <https://data-light.ru/blog/segmentacia-izobrazenij-kompjuternoe-zrenie/> (дата обращения: 13.02.2025).
11. Chen, C., Qin, C., Qiu, H., Tarroni, G., Duan, J., Bai, W., Rueckert, D. Deep learning for cardiac image segmentation: A review // arXiv preprint arXiv:2004.04931 [Электронный ресурс]. – 2020. – Режим доступа: <https://arxiv.org/ftp/arxiv/papers/2004/2004.04931.pdf> (дата обращения: 12.04.2025).
12. Современные подходы к сегментации медицинских изображений [Электронный ресурс] // Труды международной конференции студентов и молодых ученых, 2021. – С. 90–91. – Режим доступа: https://earchive.tpu.ru/bitstream/11683/68017/1/conference_tpu-2021-C04_p90-91.pdf (дата обращения: 23.04.2025).
13. Алгоритмические методы сегментации изображений [Электронный ресурс]. – Режим доступа: https://kpfu.ru/portal/docs/F265768322/Algoritmicheskie.metody.segmentacii.izobrazhenii_.pdf (дата обращения: 05.02.2025).
14. Сегментация изображений в медицине: обзор методов [Электронный ресурс] // Научный результат. Технологии бизнеса и сервиса. – 2021. – № 3 (17). – Режим доступа: <https://naukaru.ru/ru/nauka/article/37786/view> (дата обращения: 06.02.2025).
15. Как размечают медицинские изображения [Электронный ресурс] // Habr / DataLight. – 2024. – Режим доступа: https://habr.com/ru/companies/data_light/articles/855336/ (дата обращения: 11.04.2025).

16. Intel: Применение машинного обучения в медицине [Электронный ресурс] // Habr / Intel. — 2015. — Режим доступа: <https://habr.com/ru/companies/intel/articles/266347/> (дата обращения: 19.04.2025).
17. Vukadinovic, M., Kwan, A. C., Yuan, V., Salerno, M., Lee, D. C., Albert, C. M., Cheng, S., Li, D., Ouyang, D., Clarke, S. L. Deep learning-enabled analysis of medical images identifies cardiac sphericity as an early marker of cardiomyopathy and related outcomes // The Lancet Digital Health [Электронный ресурс]. — 2025. — DOI: 10.1016/S2589-7500(25)00098-2 (дата обращения: 12.06.2025).
18. ООО «Рокет Проджект» (Training Data). Что такое DICOM? [Электронный ресурс] // Разметка. Тёмная сторона ML. — Режим доступа: <https://trainingdata.ru/markup-dark-side-ml/tpost/2c5j5toet1-что-такое-dicom> (дата обращения: 26.01.2025). — Загл. с экрана.
19. Казанский федеральный университет. Алгоритмические методы сегментации изображений [Электронный ресурс]: учебное пособие. — Казань, 2024. — 45 с. — URL: https://kpfu.ru/portal/docs/F265768322/Algoritmicheskie.metody.segmentacii.izobrazhenii_.pdf (дата обращения: 03.02.2025).
20. Marker: опыт использования [Электронный ресурс] / Marker. — 06.04.2022. — Режим доступа: <https://marker.im/2022/04/06> (дата обращения: 18.01.2025).